TrabajoPractico1

April 8, 2026

1 Trabajo Practico 1

1.1 EDA sobre DJBR de la CGR

Nombre: Adrian Aguero
Materia: Introduccion a la Ciencia de Datos
Fecha: 07/04/2026

Este notebook desarrolla un analisis exploratorio de datos sobre una muestra didactica de declaraciones juradas de bienes y rentas (DJBR) de la Contraloria General de la Republica (CGR).

1.2 Objetivo

- Comprender que representan los datos y que decisiones pueden apoyar.
- Limpiar el dataset `raw` para obtener una base analizable.
- Realizar EDA univariado y bivariado con visualizaciones.
- Detectar anomalias y construir el indicador `indice_riqueza = activos_gs / ingreso_mensual_gs`.

1.3 Comprension del problema

Los datos representan declaraciones patrimoniales de funcionarios publicos: activos, pasivos, patrimonio neto, ingresos, egresos, institucion, cargo, tipo de presentacion y anio.

Con este analisis se pueden apoyar decisiones como: - identificar perfiles patrimoniales atipicos que ameriten revision; - comparar instituciones o tipos de presentacion; - priorizar auditorias o controles segun concentracion de riqueza o dispersion; - evaluar calidad de los datos y necesidades de estandarizacion.

[1]:
```
# Si trabajas en Colab y faltan librerias, descomenta la siguiente linea
# !pip install pandas matplotlib seaborn

import sys
from pathlib import Path

import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
```

```python
sns.set_theme(style='whitegrid', palette='deep')
pd.set_option('display.float_format', lambda x: f'{x:,.2f}')
```

[2]:
```python
github_base_url = 'https://raw.githubusercontent.com/afaraldo/
↪maestria-de-datos-ucom/main/ciencia-de-datos/TrabajoPractico1'

raw_path = f'{github_base_url}/cgr_djbr_muestra_taller_raw.csv'
clean_reference_path = f'{github_base_url}/cgr_djbr_muestra_taller_clean.csv'
dictionary_path = f'{github_base_url}/diccionario_datos_cgr_djbr.csv'

local_project_dir = Path('ciencia-de-datos/TrabajoPractico1')
project_dir = local_project_dir if local_project_dir.exists() else Path.cwd()
visualizations_dir = project_dir / 'visualizaciones'
visualizations_dir.mkdir(parents=True, exist_ok=True)

print('Cargando archivos directamente desde GitHub...')

df_raw = pd.read_csv(raw_path)
data_dictionary = pd.read_csv(dictionary_path)

print(f'Dimensiones raw: {df_raw.shape}')
display(data_dictionary)
display(df_raw.head())
```

```
Cargando archivos directamente desde GitHub…
Dimensiones raw: (246, 15)
```

	variable	descripcion	tipo	nota
0	registro_id	Identificador interno de la muestra didáctica	texto	No oficial
1	cedula	Identificador de persona. En muestra didáctica…	texto	No usar como clave pública
2	funcionario	Nombre o identificador del funcionario		
3	anio	Año de la declaración		
4	tipo_presentacion	Motivo o tipo de la declaración		
5	institucion	Institución principal del funcionario		
6	cargo	Cargo o rol		
7	activos_gs	Total de activos declarados		
8	pasivos_gs	Total de pasivos declarados		
9	patrimonio_neto_gs	Activos - pasivos		
10	ingreso_mensual_gs	Ingresos mensuales		
11	ingreso_anual_gs	Ingresos anuales		
12	egreso_mensual_gs	Egresos mensuales		
13	egreso_anual_gs	Egresos anuales		
14	url_pdf	Enlace al PDF público cuando existe		
15	fuente	Origen del registro		

```
2      texto          En muestra didáctica es anónimo
3     entero              Útil para series temporales
4      texto  Ej. actualización, asunción, renovación
5      texto       Variable categórica clave para EDA
6      texto     Puede tener valores faltantes en raw
7   numérico                                Guaraníes
8   numérico                                Guaraníes
9   numérico                                Guaraníes
10  numérico                                Guaraníes
11  numérico                                Guaraníes
12  numérico                                Guaraníes
13  numérico                                Guaraníes
14     texto              Solo en muestra real mínima
15     texto       Distingue real mínima vs didáctica

  registro_id   cedula      funcionario  anio       tipo_presentacion  \
0  REG-100000  1329365  FUNCIONARIO_001  2018  RENOVACION DE CONTRATO
1  REG-100001  2500942  FUNCIONARIO_002  2018       ASUNCION AL CARGO
2  REG-100002  4385659  FUNCIONARIO_003  2022       ASUNCION AL CARGO
3  REG-100003  3055555  FUNCIONARIO_004  2019           ACTUALIZACION
4  REG-100004  4613009  FUNCIONARIO_005  2024       ASUNCION AL CARGO

                     institucion                    cargo     activos_gs  \
0      Municipalidad de Asunción               Director/a  10.450.421,88
1      Municipalidad de Asunción                   Chofer  10.230.670,78
2  Instituto de Previsión Social              Enfermero/a   5.186.327,71
3                 Poder Judicial  Auxiliar jurisdiccional  61.261.763,32
4      Municipalidad de Asunción           Fiscalizador/a   1.690.858,73

     pasivos_gs patrimonio_neto_gs ingreso_mensual_gs ingreso_anual_gs  \
0          0,00      10.450.421,88       7.404.019,76     7.404.019,76
1  3.188.590,87       7.042.079,91      18.116.820,55             0,00
2  2.216.252,32       2.970.075,39       6.769.831,95             0,00
3          0,00      61.261.763,32       4.325.185,08             0,00
4          0,00       1.690.858,73      15.521.937,29             0,00

  egreso_mensual_gs egreso_anual_gs  \
0      4.505.193,91    3.253.621,83
1      6.704.423,57   10.608.585,72
2      2.558.808,17    3.871.579,19
3      1.852.742,84             NaN
4      7.604.073,56    4.094.260,35

                                            fuente
0  Muestra didáctica inspirada en campos visibles…
1  Muestra didáctica inspirada en campos visibles…
2  Muestra didáctica inspirada en campos visibles…
3  Muestra didáctica inspirada en campos visibles…
```

```
4  Muestra didáctica inspirada en campos visibles…
```

1.4 Exploracion inicial

Se revisan estructura, tipos y calidad inicial del dataset.

[3]:
```python
display(df_raw.info())
display(df_raw.isna().sum().sort_values(ascending=False).to_frame('nulos'))
print(f'Duplicados exactos: {df_raw.duplicated().sum()}')
display(df_raw.describe(include='all').T.head(15))
```

```
<class 'pandas.DataFrame'>
RangeIndex: 246 entries, 0 to 245
Data columns (total 15 columns):
 #   Column              Non-Null Count  Dtype
---  ------              --------------  -----
 0   registro_id         246 non-null    str
 1   cedula              246 non-null    int64
 2   funcionario         246 non-null    str
 3   anio                246 non-null    int64
 4   tipo_presentacion   242 non-null    str
 5   institucion         246 non-null    str
 6   cargo               242 non-null    str
 7   activos_gs          246 non-null    str
 8   pasivos_gs          246 non-null    str
 9   patrimonio_neto_gs  246 non-null    str
 10  ingreso_mensual_gs  246 non-null    str
 11  ingreso_anual_gs    246 non-null    str
 12  egreso_mensual_gs   246 non-null    str
 13  egreso_anual_gs     128 non-null    str
 14  fuente              246 non-null    str
dtypes: int64(2), str(13)
memory usage: 29.0 KB
```

```
None
```

```
                    nulos
egreso_anual_gs       118
cargo                   4
tipo_presentacion       4
funcionario             0
cedula                  0
anio                    0
registro_id             0
institucion             0
activos_gs              0
patrimonio_neto_gs      0
pasivos_gs              0
ingreso_mensual_gs      0
```

```
ingreso_anual_gs        0
egreso_mensual_gs       0
fuente                  0

Duplicados exactos: 6

                    count unique  \
registro_id           246    240
cedula             246.00    NaN
funcionario           246    240
anio               246.00    NaN
tipo_presentacion     242      5
institucion           246     17
cargo                 242     20
activos_gs            246    240
pasivos_gs            246    180
patrimonio_neto_gs    246    240
ingreso_mensual_gs    246    239
ingreso_anual_gs      246    104
egreso_mensual_gs     246    240
egreso_anual_gs       128    126
fuente                246      1

                                                                 top freq  \
registro_id                                                 REG-100003    2
cedula                                                             NaN  NaN
funcionario                                             FUNCIONARIO_004    2
anio                                                               NaN  NaN
tipo_presentacion                                         ACTUALIZACION   79
institucion            Ministerio de Salud Pública y Bienestar Social   42
cargo                                                Administrativo/a   50
activos_gs                                             61.261.763,32    2
pasivos_gs                                                      0,00   63
patrimonio_neto_gs                                     61.261.763,32    2
ingreso_mensual_gs                                      4.325.185,08    2
ingreso_anual_gs                                                0,00  139
egreso_mensual_gs                                       1.852.742,84    2
egreso_anual_gs                                         2.805.030,65    2
fuente              Muestra didáctica inspirada en campos visibles…  246

                          mean          std          min          25%  \
registro_id                NaN          NaN          NaN          NaN
cedula             3,134,354.36 1,137,180.93 1,010,699.00 2,089,458.50
funcionario                NaN          NaN          NaN          NaN
anio                  2,021.00         2.01     2,018.00     2,019.00
tipo_presentacion          NaN          NaN          NaN          NaN
institucion                NaN          NaN          NaN          NaN
cargo                      NaN          NaN          NaN          NaN
activos_gs                 NaN          NaN          NaN          NaN
```

```
pasivos_gs                  NaN          NaN          NaN          NaN
patrimonio_neto_gs          NaN          NaN          NaN          NaN
ingreso_mensual_gs          NaN          NaN          NaN          NaN
ingreso_anual_gs            NaN          NaN          NaN          NaN
egreso_mensual_gs           NaN          NaN          NaN          NaN
egreso_anual_gs             NaN          NaN          NaN          NaN
fuente                      NaN          NaN          NaN          NaN

                            50%          75%          max
registro_id                 NaN          NaN          NaN
cedula             3,265,985.00 4,093,755.50 4,978,400.00
funcionario                 NaN          NaN          NaN
anio                   2,021.00     2,023.00     2,024.00
tipo_presentacion           NaN          NaN          NaN
institucion                 NaN          NaN          NaN
cargo                       NaN          NaN          NaN
activos_gs                  NaN          NaN          NaN
pasivos_gs                  NaN          NaN          NaN
patrimonio_neto_gs          NaN          NaN          NaN
ingreso_mensual_gs          NaN          NaN          NaN
ingreso_anual_gs            NaN          NaN          NaN
egreso_mensual_gs           NaN          NaN          NaN
egreso_anual_gs             NaN          NaN          NaN
fuente                      NaN          NaN          NaN
```

1.5 Limpieza de datos

Se trabaja desde el archivo `raw` para que la limpieza sea reproducible. A continuacion, la limpieza queda separada en pasos numerados.

[4]:
```
text_columns = ['registro_id', 'cedula', 'funcionario', 'tipo_presentacion',␣
 ↪'institucion', 'cargo', 'fuente']
numeric_columns = [
    'activos_gs',
    'pasivos_gs',
    'patrimonio_neto_gs',
    'ingreso_mensual_gs',
    'ingreso_anual_gs',
    'egreso_mensual_gs',
    'egreso_anual_gs',
]

def parse_local_decimal(series):
    cleaned = (
        series.astype(str)
        .str.strip()
        .replace({'': np.nan, 'nan': np.nan, 'None': np.nan})
        .str.replace('.', '', regex=False)
```

```
        .str.replace(',', '.', regex=False)
    )
    return pd.to_numeric(cleaned, errors='coerce')

df = df_raw.copy()
```

1.5.1 1. Eliminacion de duplicados

Se remueven filas completamente repetidas para evitar sesgos en el analisis.

[5]:
```
df = df.drop_duplicates().reset_index(drop=True)
print(f'Forma luego de eliminar duplicados: {df.shape}')
```

```
Forma luego de eliminar duplicados: (240, 15)
```

1.5.2 2. Normalizacion de columnas de texto

Se limpian espacios sobrantes y se completan faltantes categoricos con `No especificado`.

[6]:
```
for col in text_columns:
    df[col] = df[col].astype(str).str.strip()

df['tipo_presentacion'] = df['tipo_presentacion'].replace({'nan': np.nan}).
 ↪fillna('No especificado')
df['cargo'] = df['cargo'].replace({'nan': np.nan}).fillna('No especificado')
print(f'Forma luego de normalizar texto: {df.shape}')
```

```
Forma luego de normalizar texto: (240, 15)
```

1.5.3 3. Conversion de montos y relleno de nulos numericos

Los montos se convierten desde formato local a numerico y luego los faltantes en columnas numericas se reemplazan por `0`.

[7]:
```
for col in numeric_columns:
    df[col] = parse_local_decimal(df[col])

df[numeric_columns] = df[numeric_columns].fillna(0)
df['anio'] = pd.to_numeric(df['anio'], errors='coerce').astype('Int64')
print(f'Forma luego de convertir tipos y completar nulos: {df.shape}')
```

```
Forma luego de convertir tipos y completar nulos: (240, 15)
```

1.5.4 4. Outliers

Se identifican outliers en las variables numericas con el criterio IQR y luego se eliminan del `dataframe` antes del analisis.

[8]:
```
def outlier_bounds(series):
    q1 = series.quantile(0.25)
```

```
    q3 = series.quantile(0.75)
    iqr = q3 - q1
    return q1 - 1.5 * iqr, q3 + 1.5 * iqr

outlier_report_cleaning = []
outlier_mask = pd.Series(False, index=df.index)
for col in numeric_columns:
    lower, upper = outlier_bounds(df[col].dropna())
    col_mask = df[col].lt(lower) | df[col].gt(upper)
    outlier_mask |= col_mask
    outlier_report_cleaning.append({
        'variable': col,
        'limite_inferior': lower,
        'limite_superior': upper,
        'cantidad_outliers': int(col_mask.sum()),
    })

outliers_eliminados = int(outlier_mask.sum())
df = df.loc[~outlier_mask].reset_index(drop=True)

display(pd.DataFrame(outlier_report_cleaning))
print(f'Filas eliminadas por outliers: {outliers_eliminados}')
print(f'Forma luego de eliminar outliers: {df.shape}')
```

	variable	limite_inferior	limite_superior	cantidad_outliers
0	activos_gs	-17,261,799.34	42,402,577.08	31
1	pasivos_gs	-4,726,909.31	7,878,182.18	25
2	patrimonio_neto_gs	-16,280,730.08	37,202,577.15	28
3	ingreso_mensual_gs	249,172.64	11,180,015.41	15
4	ingreso_anual_gs	-7,530,827.02	12,551,378.38	2
5	egreso_mensual_gs	-383,250.70	6,888,185.18	8
6	egreso_anual_gs	-2,401,976.71	4,003,294.51	9

```
Filas eliminadas por outliers: 58
Forma luego de eliminar outliers: (182, 15)
```

1.5.5 5. Control de calidad

Se comparan metricas basicas entre la base original y la base limpia para verificar el resultado final de la limpieza.

[9]:
```
quality_summary = pd.DataFrame({
    'raw': {
        'filas': len(df_raw),
        'duplicados': int(df_raw.duplicated().sum()),
        'nulos_tipo_presentacion': int(df_raw['tipo_presentacion'].isna().
 ↪sum()),
        'nulos_cargo': int(df_raw['cargo'].isna().sum()),
```

```
        'nulos_numericos': int(df_raw[numeric_columns].isna().sum().sum()),
    },
    'clean_reproducido': {
        'filas': len(df),
        'duplicados': int(df.duplicated().sum()),
        'nulos_tipo_presentacion': int(df['tipo_presentacion'].isna().sum()),
        'nulos_cargo': int(df['cargo'].isna().sum()),
        'nulos_numericos': int(df[numeric_columns].isna().sum().sum()),
        'outliers_eliminados': outliers_eliminados,
    }
})

print(f'Forma final luego del control de calidad: {df.shape}')
display(quality_summary)
display(df.head())
```

```
Forma final luego del control de calidad: (182, 15)

                          raw  clean_reproducido
filas                  246.00                182
duplicados               6.00                  0
nulos_tipo_presentacion  4.00                  0
nulos_cargo              4.00                  0
nulos_numericos        118.00                  0
outliers_eliminados       NaN                 58

  registro_id   cedula      funcionario  anio       tipo_presentacion  \
0  REG-100000  1329365  FUNCIONARIO_001  2018  RENOVACION DE CONTRATO
1  REG-100002  4385659  FUNCIONARIO_003  2022       ASUNCION AL CARGO
2  REG-100005  2504384  FUNCIONARIO_006  2022       ASUNCION AL CARGO
3  REG-100006  4521441  FUNCIONARIO_007  2018           ACTUALIZACION
4  REG-100007  1214020  FUNCIONARIO_008  2020  RENOVACION DE CONTRATO

                                     institucion             cargo  \
0                      Municipalidad de Asunción        Director/a
1                   Instituto de Previsión Social       Enfermero/a
2   Ministerio de Obras Públicas y Comunicaciones         Técnico/a
3                                           ESSAP  Administrativo/a
4  Ministerio de Salud Pública y Bienestar Social            Chofer

     activos_gs   pasivos_gs  patrimonio_neto_gs  ingreso_mensual_gs  \
0 10,450,421.88         0.00       10,450,421.88        7,404,019.76
1  5,186,327.71 2,216,252.32        2,970,075.39        6,769,831.95
2 29,182,531.09         0.00       29,182,531.09        9,932,453.84
3 13,363,091.64         0.00       13,363,091.64        4,651,977.53
4  3,705,335.35 1,118,899.78        2,586,435.57        5,121,548.56

   ingreso_anual_gs  egreso_mensual_gs  egreso_anual_gs  \
0      7,404,019.76       4,505,193.91     3,253,621.83
```

```
1              0.00       2,558,808.17     3,871,579.19
2              0.00       5,284,687.58             0.00
3      4,651,977.53       2,875,006.75             0.00
4              0.00       3,932,510.39     2,647,341.78

                                                fuente
0  Muestra didáctica inspirada en campos visibles…
1  Muestra didáctica inspirada en campos visibles…
2  Muestra didáctica inspirada en campos visibles…
3  Muestra didáctica inspirada en campos visibles…
4  Muestra didáctica inspirada en campos visibles…
```

1.6 EDA

1.6.1 Estadistica descriptiva

Se resume la distribucion de las variables numericas principales y la composicion del dataset por institucion, tipo de presentacion y anio.

[10]:
```
summary = df[numeric_columns].describe(percentiles=[0.25, 0.5, 0.75, 0.9, 0.95,␣
↪0.99]).T
show_columns = ['mean', '50%', 'std', 'min', 'max']
display(summary)
display(summary[show_columns].rename(columns={'mean': 'promedio', '50%':␣
↪'mediana', 'std': 'desvio'}))

top_instituciones = df['institucion'].value_counts().head(10)
tipo_counts = df['tipo_presentacion'].value_counts()
anio_counts = df['anio'].value_counts().sort_index()

display(top_instituciones.to_frame('cantidad'))
display(tipo_counts.to_frame('cantidad'))
display(anio_counts.to_frame('cantidad'))
```

```
                    count         mean          std          min          25%  \
activos_gs         182.00 9,909,028.15 7,426,870.28   276,746.33 4,582,835.91
pasivos_gs         182.00 1,405,606.88 1,778,147.71         0.00         0.00
patrimonio_neto_gs 182.00 8,503,421.27 7,103,673.63   217,196.87 3,107,890.31
ingreso_mensual_gs 182.00 5,420,059.16 1,926,854.49 1,200,000.00 4,087,805.55
ingreso_anual_gs   182.00 2,232,722.92 2,885,353.51         0.00         0.00
egreso_mensual_gs  182.00 3,046,195.18 1,246,041.73   613,300.11 2,178,785.12
egreso_anual_gs    182.00   807,911.03 1,062,778.00         0.00         0.00

                            50%           75%           90%           95%  \
activos_gs         7,803,896.96 14,117,671.40 20,310,041.40 25,482,656.88
pasivos_gs           645,103.91  2,020,756.35  4,167,914.05  5,374,979.28
patrimonio_neto_gs 6,347,299.54 11,750,087.42 18,679,554.95 22,372,387.93
ingreso_mensual_gs 5,256,355.24  6,495,223.95  7,759,678.83  9,080,471.62
ingreso_anual_gs           0.00  4,796,503.58  6,181,968.55  7,118,894.01
```

```
egreso_mensual_gs  2,873,843.94  3,909,289.86  4,762,066.97  5,351,929.33
egreso_anual_gs      269,879.66  1,448,720.40  2,643,186.49  3,012,925.53

                            99%           max
activos_gs         29,860,548.46 35,517,709.35
pasivos_gs          6,766,874.63  7,601,697.04
patrimonio_neto_gs 29,860,548.46 35,517,709.35
ingreso_mensual_gs 10,717,734.26 11,026,475.09
ingreso_anual_gs    9,391,353.86 10,748,698.48
egreso_mensual_gs   5,991,398.19  6,046,976.06
egreso_anual_gs     3,514,243.47  3,871,579.19

                       promedio      mediana       desvio          min  \
activos_gs         9,909,028.15 7,803,896.96 7,426,870.28   276,746.33
pasivos_gs         1,405,606.88   645,103.91 1,778,147.71         0.00
patrimonio_neto_gs 8,503,421.27 6,347,299.54 7,103,673.63   217,196.87
ingreso_mensual_gs 5,420,059.16 5,256,355.24 1,926,854.49 1,200,000.00
ingreso_anual_gs   2,232,722.92         0.00 2,885,353.51         0.00
egreso_mensual_gs  3,046,195.18 2,873,843.94 1,246,041.73   613,300.11
egreso_anual_gs      807,911.03   269,879.66 1,062,778.00         0.00

                            max
activos_gs         35,517,709.35
pasivos_gs          7,601,697.04
patrimonio_neto_gs 35,517,709.35
ingreso_mensual_gs 11,026,475.09
ingreso_anual_gs   10,748,698.48
egreso_mensual_gs   6,046,976.06
egreso_anual_gs     3,871,579.19

                                                 cantidad
institucion
Ministerio de Salud Pública y Bienestar Social         38
Ministerio de Educación y Ciencias                     31
Instituto de Previsión Social                          25
ESSAP                                                  17
Universidad Nacional de Asunción                       15
Ministerio de Obras Públicas y Comunicaciones          14
Municipalidad de Asunción                              11
Gobernación de Central                                 11
Poder Judicial                                          8
Ministerio de Economía y Finanzas                       5

                       cantidad
tipo_presentacion
ACTUALIZACION                56
ASUNCION AL CARGO            51
RENOVACION DE CONTRATO       27
OTRO                         27
```

```
CESE                          17
No especificado                4
```

```
      cantidad
anio
2018        22
2019        35
2020        26
2021        27
2022        25
2023        20
2024        27
```

1.6.2 Analisis univariado

Se revisan variables individuales para entender dispersion, asimetria y concentracion de observaciones antes de comparar relaciones entre columnas.

[11]:
```
univariate_summary = pd.DataFrame({
    'variable': ['activos_gs', 'patrimonio_neto_gs', 'ingreso_mensual_gs'],
    'mediana': [df['activos_gs'].median(), df['patrimonio_neto_gs'].median(),␣
 ↪df['ingreso_mensual_gs'].median()],
    'promedio': [df['activos_gs'].mean(), df['patrimonio_neto_gs'].mean(),␣
 ↪df['ingreso_mensual_gs'].mean()],
    'asimetria': [df['activos_gs'].skew(), df['patrimonio_neto_gs'].skew(),␣
 ↪df['ingreso_mensual_gs'].skew()],
})

display(univariate_summary)
display(top_instituciones.head(5).to_frame('cantidad'))
```

```
             variable      mediana     promedio  asimetria
0          activos_gs 7,803,896.96 9,909,028.15       1.12
1  patrimonio_neto_gs 6,347,299.54 8,503,421.27       1.32
2  ingreso_mensual_gs 5,256,355.24 5,420,059.16       0.49
```

```
                                                 cantidad
institucion
Ministerio de Salud Pública y Bienestar Social         38
Ministerio de Educación y Ciencias                     31
Instituto de Previsión Social                          25
ESSAP                                                  17
Universidad Nacional de Asunción                       15
```

1.6.3 Analisis bivariado

Se exploran relaciones entre activos, patrimonio e ingresos para verificar si el ingreso mensual acompana el nivel patrimonial declarado.

[12]:
```
corr = df[['anio'] + numeric_columns].corr(numeric_only=True)
correlaciones_clave = corr.loc[
    ['activos_gs', 'patrimonio_neto_gs'],
    ['ingreso_mensual_gs', 'egreso_mensual_gs', 'ingreso_anual_gs']
]

display(correlaciones_clave)

median_by_type = (
    df.groupby('tipo_presentacion')[['patrimonio_neto_gs',␣
 ↪'ingreso_mensual_gs']]
    .median()
    .sort_values('patrimonio_neto_gs', ascending=False)
)
median_by_institucion = (
    df.groupby('institucion')[['patrimonio_neto_gs', 'ingreso_mensual_gs']]
    .median()
    .sort_values('patrimonio_neto_gs', ascending=False)
    .head(10)
)

display(median_by_type)
display(median_by_institucion)

plt.figure(figsize=(10, 8))
sns.heatmap(corr, annot=True, cmap='Blues', fmt='.2f')
plt.title('Correlaciones entre variables numericas base')
plt.tight_layout()
heatmap_path = visualizations_dir / 'heatmap_correlaciones.png'
plt.savefig(heatmap_path, dpi=150, bbox_inches='tight')
plt.show()
plt.close()
print(f'Grafico guardado en: {heatmap_path}')
```

```
                    ingreso_mensual_gs  egreso_mensual_gs  ingreso_anual_gs
activos_gs                        0.26               0.16              0.12
patrimonio_neto_gs                0.27               0.18              0.13

                       patrimonio_neto_gs  ingreso_mensual_gs
tipo_presentacion
No especificado               9,608,070.96        5,374,778.95
ACTUALIZACION                 6,814,956.28        5,220,211.89
CESE                          6,063,007.01        5,354,021.53
ASUNCION AL CARGO             5,641,587.66        5,551,526.51
RENOVACION DE CONTRATO        5,455,103.88        5,826,295.61
OTRO                          5,283,859.03        4,380,780.72

                                                 patrimonio_neto_gs  \
institucion
```

poder judicial	31,926,150.71
MINISTERIO DE OBRAS PÚBLICAS Y COMUNICACIONES	17,693,259.74
Ministerio de Economía y Finanzas	14,540,307.29
instituto de previsión social	13,644,319.94
Gobernación de Central	12,715,639.44
Poder Judicial	9,711,654.51
Ministerio de Obras Públicas y Comunicaciones	8,090,746.41
Universidad Nacional de Asunción	7,915,406.55
Municipalidad de Asunción	7,377,294.90
Ministerio de Educación y Ciencias	7,231,278.26

institucion	ingreso_mensual_gs
poder judicial	10,710,471.05
MINISTERIO DE OBRAS PÚBLICAS Y COMUNICACIONES	4,886,792.08
Ministerio de Economía y Finanzas	7,588,938.37
instituto de previsión social	5,751,698.06
Gobernación de Central	6,504,736.05
Poder Judicial	8,173,568.59
Ministerio de Obras Públicas y Comunicaciones	5,819,409.25
Universidad Nacional de Asunción	5,386,638.88
Municipalidad de Asunción	7,404,019.76
Ministerio de Educación y Ciencias	4,090,121.53

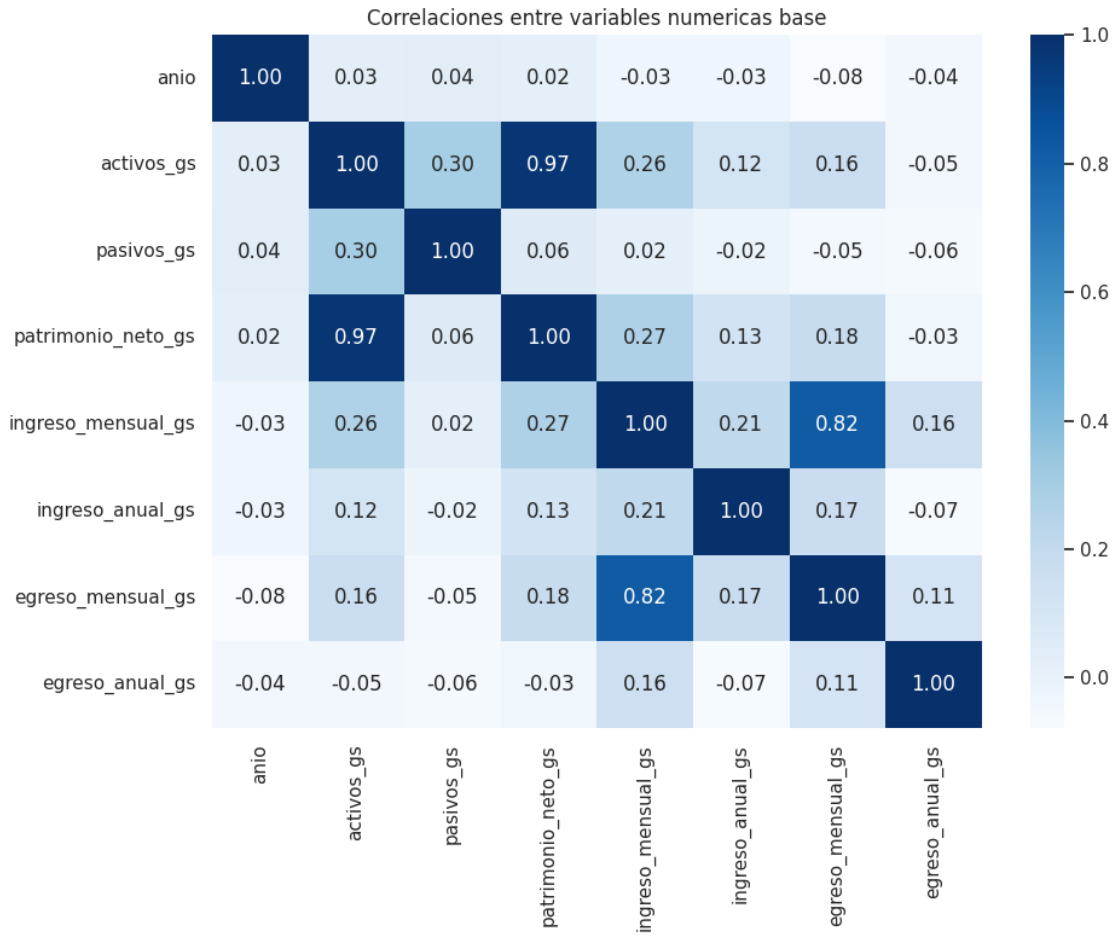


```
Grafico guardado en: /home/afaraldo/RubymineProjects/maestria-de-datos-
ucom/ciencia-de-datos/TrabajoPractico1/visualizaciones/heatmap_correlaciones.png
```

1.7 Visualizacion

Las visualizaciones se generan, se guardan en archivos dentro de `visualizaciones/` y tambien se muestran incrustadas en este notebook al ejecutarlo.

[13]:
```
saved_visualizations = []

plt.figure(figsize=(10, 5))
sns.histplot(df['activos_gs'], bins=30, kde=True)
plt.title('Histograma de activos')
plt.xlabel('Activos (Gs)')
plt.ylabel('Frecuencia')
plt.tight_layout()
hist_path = visualizations_dir / 'histograma_activos.png'
plt.savefig(hist_path, dpi=150, bbox_inches='tight')
```

```
plt.show()
plt.close()
saved_visualizations.append(hist_path)

plt.figure(figsize=(10, 3))
sns.boxplot(x=df['patrimonio_neto_gs'])
plt.title('Boxplot de patrimonio neto')
plt.xlabel('Patrimonio neto (Gs)')
plt.tight_layout()
boxplot_path = visualizations_dir / 'boxplot_patrimonio.png'
plt.savefig(boxplot_path, dpi=150, bbox_inches='tight')
plt.show()
plt.close()
saved_visualizations.append(boxplot_path)

plt.figure(figsize=(10, 6))
sns.barplot(x=top_instituciones.values, y=top_instituciones.index)
plt.title('Top 10 instituciones por cantidad de registros')
plt.xlabel('Cantidad')
plt.ylabel('Institucion')
plt.tight_layout()
barplot_path = visualizations_dir / 'barras_instituciones.png'
plt.savefig(barplot_path, dpi=150, bbox_inches='tight')
plt.show()
plt.close()
saved_visualizations.append(barplot_path)

plt.figure(figsize=(10, 6))
sns.scatterplot(data=df, x='ingreso_mensual_gs', y='activos_gs',␣
 ↪hue='tipo_presentacion', alpha=0.7)
plt.title('Scatter de activos vs ingreso mensual')
plt.xlabel('Ingreso mensual (Gs)')
plt.ylabel('Activos (Gs)')
plt.tight_layout()
scatter_path = visualizations_dir / 'scatter_activos_ingresos.png'
plt.savefig(scatter_path, dpi=150, bbox_inches='tight')
plt.show()
plt.close()
saved_visualizations.append(scatter_path)

for saved_path in saved_visualizations:
    print(f'Grafico guardado en: {saved_path}')
```

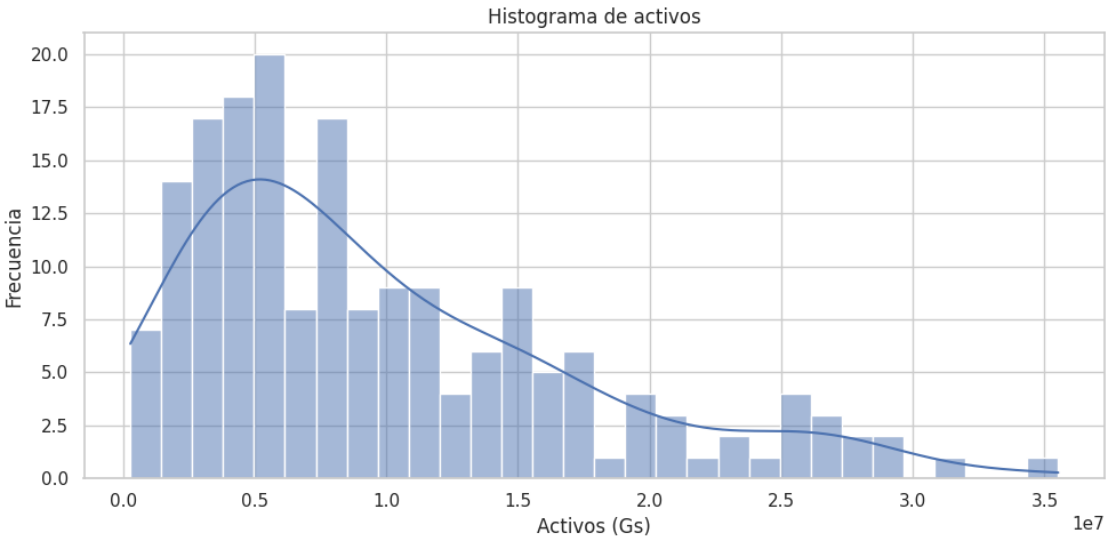
Histograma de activos
Frecuencia
20.0
17.5
15.0
12.5
10.0
7.5
5.0
2.5
0.0
0.0
0.5
1.0
1.5
2.0
2.5
3.0
3.5
Activos (Gs)
1e7

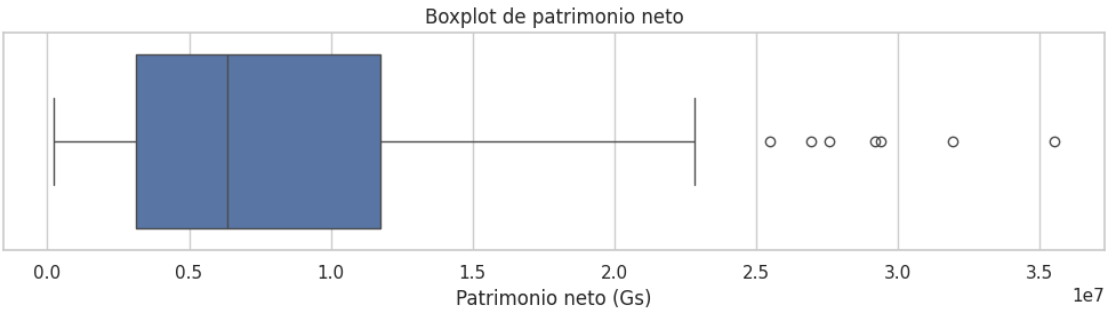
Boxplot de patrimonio neto
0.0
0.5
1.0
1.5
2.0
2.5
3.0
3.5
Patrimonio neto (Gs)
1e7

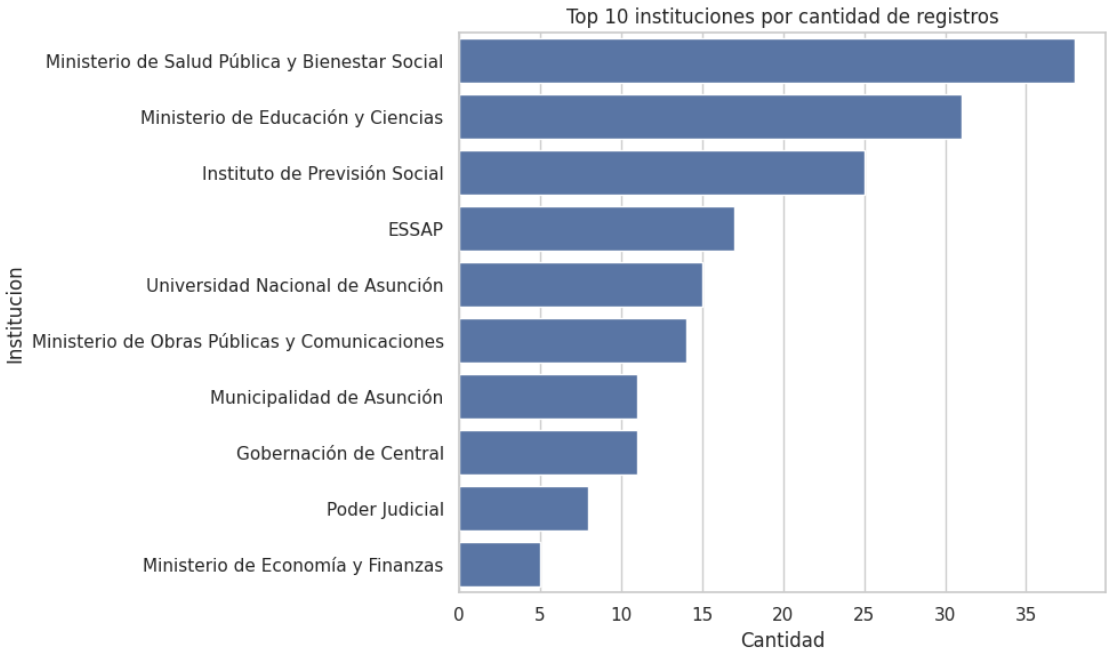

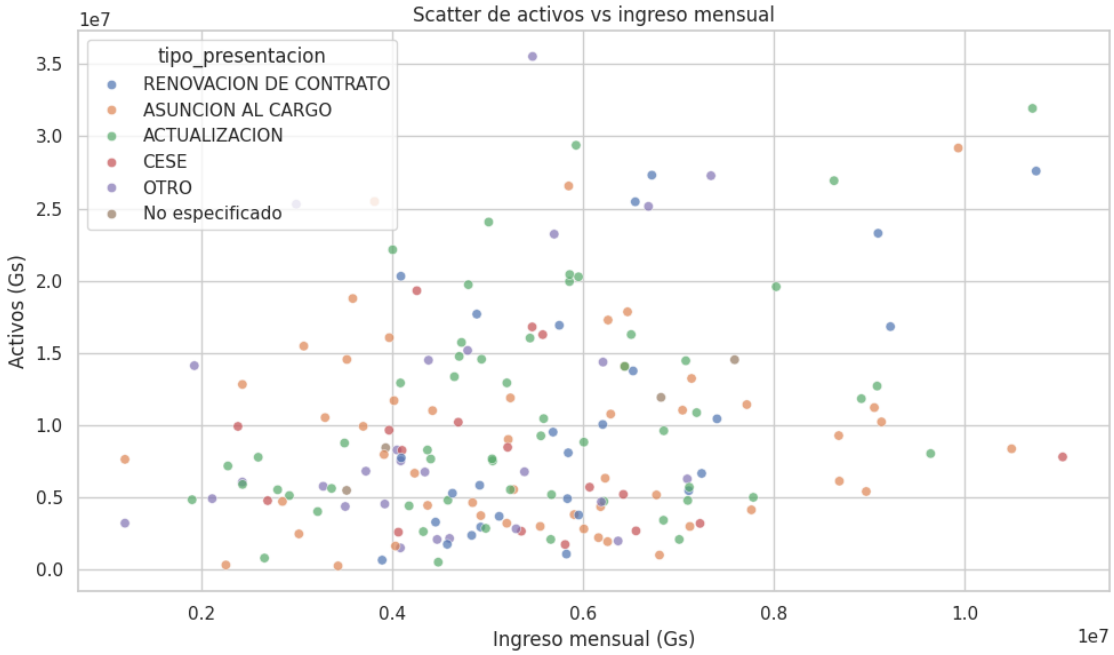


```
Grafico guardado en: /home/afaraldo/RubymineProjects/maestria-de-datos-
ucom/ciencia-de-datos/TrabajoPractico1/visualizaciones/histograma_activos.png
Grafico guardado en: /home/afaraldo/RubymineProjects/maestria-de-datos-
ucom/ciencia-de-datos/TrabajoPractico1/visualizaciones/boxplot_patrimonio.png
```

```
Grafico guardado en: /home/afaraldo/RubymineProjects/maestria-de-datos-
ucom/ciencia-de-datos/TrabajoPractico1/visualizaciones/barras_instituciones.png
Grafico guardado en: /home/afaraldo/RubymineProjects/maestria-de-datos-
ucom/ciencia-de-
datos/TrabajoPractico1/visualizaciones/scatter_activos_ingresos.png
```

1.8 Anomalias

Se identifican valores extremos sobre variables base del dataset para detectar registros que merecen una revision puntual.

[14]:
```
outlier_report = []
variables_anomalias = ['activos_gs', 'patrimonio_neto_gs', 'ingreso_mensual_gs']

for variable in variables_anomalias:
    lower, upper = outlier_bounds(df[variable].dropna())
    outliers = df[df[variable].lt(lower) | df[variable].gt(upper)]
    outlier_report.append({
        'variable': variable,
        'limite_inferior': lower,
        'limite_superior': upper,
        'cantidad_outliers': int(len(outliers)),
        'maximo': df[variable].max(),
    })

outlier_report_df = pd.DataFrame(outlier_report)
display(outlier_report_df)

outliers_activos = df[[
    'registro_id',
    'institucion',
    'cargo',
    'activos_gs',
    'patrimonio_neto_gs',
    'ingreso_mensual_gs',
]].sort_values('activos_gs', ascending=False).head(10)
display(outliers_activos)
```

```
             variable  limite_inferior  limite_superior  cantidad_outliers  \
0          activos_gs    -9,719,417.34    28,419,924.65                  4
1  patrimonio_neto_gs    -9,855,405.35    24,713,383.08                  7
2  ingreso_mensual_gs       476,677.95    10,106,351.55                  4

         maximo
0 35,517,709.35
1 35,517,709.35
2 11,026,475.09

    registro_id                                        institucion  \
```

```
35   REG-100046              Ministerio de Economía y Finanzas
166  REG-100220                                   poder judicial
173  REG-100229  Ministerio de Salud Pública y Bienestar Social
2    REG-100005   Ministerio de Obras Públicas y Comunicaciones
112  REG-100148                                   Poder Judicial
119  REG-100159  Ministerio de Salud Pública y Bienestar Social
48   REG-100061                         Gobernación de Central
147  REG-100193                                   Poder Judicial
150  REG-100199                       Municipalidad de Asunción
14   REG-100019  Ministerio de Salud Pública y Bienestar Social

               cargo    activos_gs  patrimonio_neto_gs  ingreso_mensual_gs
35        Director/a 35,517,709.35       35,517,709.35        5,471,230.92
166     Secretario/a 31,926,150.71       31,926,150.71       10,710,471.05
173        Técnico/a 29,376,024.47       29,376,024.47        5,927,160.48
2          Técnico/a 29,182,531.09       29,182,531.09        9,932,453.84
112       Actuario/a 27,589,356.93       27,589,356.93       10,748,698.48
119  No especificado 27,308,385.10       22,258,587.93        6,721,306.83
48         Técnico/a 27,269,455.24       22,490,034.02        7,340,974.01
147       Actuario/a 26,924,641.80       26,924,641.80        8,630,534.60
150           Chofer 26,556,912.40       22,804,278.18        5,850,073.69
14            Chofer 25,483,651.29       25,483,651.29        3,815,331.77
```

1.9 Indicadores

Se construye el indicador final solicitado: `indice_riqueza = bienes / ingresos`, usando `activos_gs / ingreso_mensual_gs` cuando el ingreso mensual es mayor a cero.

[15]:
```
df['indice_riqueza'] = np.where(df['ingreso_mensual_gs'] > 0, df['activos_gs'] /
 ↪ df['ingreso_mensual_gs'], np.nan)

indice_summary = df['indice_riqueza'].describe(percentiles=[0.25, 0.5, 0.75, 0.
 ↪9, 0.95, 0.99]).to_frame('indice_riqueza')
display(indice_summary)

plt.figure(figsize=(10, 3))
sns.boxplot(x=df['indice_riqueza'])
plt.title('Boxplot del indice de riqueza')
plt.xlabel('Bienes / ingresos')
plt.tight_layout()
indice_boxplot_path = visualizations_dir / 'boxplot_indice_riqueza.png'
plt.savefig(indice_boxplot_path, dpi=150, bbox_inches='tight')
plt.show()
plt.close()
print(f'Grafico guardado en: {indice_boxplot_path}')

lower_indice, upper_indice = outlier_bounds(df['indice_riqueza'].dropna())
```

```
outliers_indice_riqueza = df[df['indice_riqueza'].lt(lower_indice) |␣
↪df['indice_riqueza'].gt(upper_indice)]

display(pd.DataFrame([{
    'variable': 'indice_riqueza',
    'limite_inferior': lower_indice,
    'limite_superior': upper_indice,
    'cantidad_outliers': int(len(outliers_indice_riqueza)),
    'maximo': df['indice_riqueza'].max(),
}]))

top_indice_riqueza = df[[
    'registro_id',
    'institucion',
    'cargo',
    'activos_gs',
    'ingreso_mensual_gs',
    'indice_riqueza',
]].sort_values('indice_riqueza', ascending=False).head(10)
display(top_indice_riqueza)
```

```
       indice_riqueza
count          182.00
mean             1.98
std              1.53
min              0.08
25%              0.76
50%              1.67
75%              2.76
90%              4.06
95%              4.96
99%              6.80
max              8.45
```

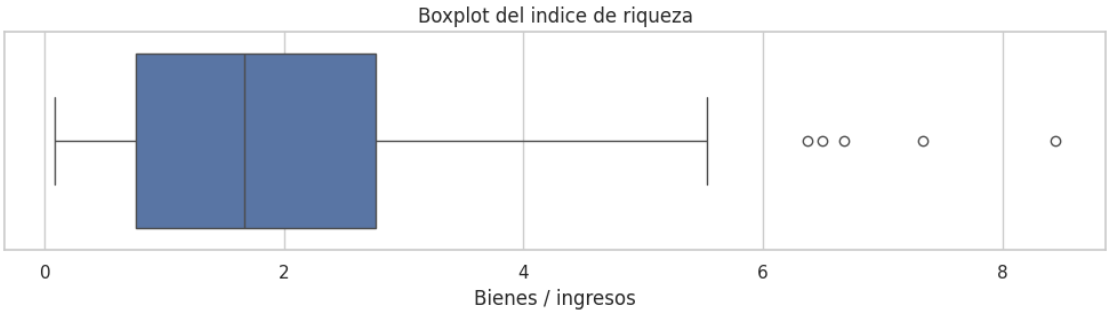


```
Grafico guardado en: /home/afaraldo/RubymineProjects/maestria-de-datos-
ucom/ciencia-de-
```

```
datos/TrabajoPractico1/visualizaciones/boxplot_indice_riqueza.png

         variable  limite_inferior  limite_superior  cantidad_outliers  maximo
0  indice_riqueza            -2.23             5.76                  5    8.45

    registro_id                                      institucion         cargo  \
33   REG-100044                                            ESSAP     Seguridad
96   REG-100129                                            ESSAP     Seguridad
14   REG-100019  Ministerio de Salud Pública y Bienestar Social        Chofer
35   REG-100046               Ministerio de Economía y Finanzas    Director/a
39   REG-100050   Ministerio de Obras Públicas y Comunicaciones     Técnico/a
145  REG-100191              Ministerio de Educación y Ciencias     Técnico/a
154  REG-100204              Ministerio de Educación y Ciencias  Supervisor/a
165  REG-100219                   Instituto de Previsión Social     Técnico/a
69   REG-100093                   Instituto de Previsión Social   Enfermero/a
132  REG-100173                                            ESSAP     Seguridad

       activos_gs  ingreso_mensual_gs  indice_riqueza
33  25,294,274.09        2,995,095.31            8.45
96  14,128,752.90        1,926,946.80            7.33
14  25,483,651.29        3,815,331.77            6.68
35  35,517,709.35        5,471,230.92            6.49
39   7,647,065.89        1,200,000.00            6.37
145 22,147,605.49        4,005,490.75            5.53
154 12,830,375.34        2,430,448.84            5.28
165 18,773,477.59        3,587,596.06            5.23
69  15,480,283.80        3,074,114.65            5.04
132 20,313,903.52        4,091,350.60            4.97
```

1.10 Informe

El analisis realizado muestra que la base de datos requeria un proceso previo de limpieza para garantizar resultados consistentes, debido a la presencia de duplicados, valores faltantes y valores atipicos. Una vez depurada, la muestra permitio identificar patrones relevantes en la composicion patrimonial y de ingresos declarados.

En primer lugar, se observa que las variables patrimoniales, especialmente `activos_gs` y `patrimonio_neto_gs`, presentan una distribucion sesgada hacia la derecha. Esto indica que la mayor parte de los registros se concentra en niveles medios o bajos, mientras que un grupo reducido acumula montos considerablemente mas altos.

En segundo lugar, la relacion entre el ingreso mensual y las variables patrimoniales es baja, lo que sugiere que el nivel de activos o patrimonio neto no puede explicarse unicamente a partir del ingreso corriente declarado. Este resultado refuerza la necesidad de analizar los registros desde una perspectiva mas amplia y no solo salarial.

Tambien se identifican diferencias segun el tipo de presentacion y la institucion declarada, lo que permite reconocer perfiles distintos dentro del conjunto analizado. Esto resulta util para futuras segmentaciones o revisiones focalizadas.

Por ultimo, la construccion del `indice_riqueza` permitio detectar casos con niveles de bienes

relativamente altos en comparacion con el ingreso mensual, funcionando como un indicador complementario para senalar observaciones que merecen una revision mas detallada.

1.11 Recomendaciones

- Revisar manualmente los casos con mayor `indice_riqueza`.
- Fortalecer la normalizacion de variables categoricas como `institucion` y `cargo`.
- Evaluar con mayor cuidado las variables anuales, debido a su alta presencia de ceros o faltantes.
- Mantener un flujo de limpieza reproducible como paso obligatorio antes de cualquier analisis posterior.